

Sistema Embarcado para Monitoramento e Predição de Deterioração Clínica Intra-hospitalar

Embedded System for Monitoring and Prediction of Intra-Hospital Clinical Deterioration

Alberto Magno Machado¹
Gabriel Luís Pinto Cecconello²
Paula Cristina Talim Gonçalves³
Pedro Henrique de Rezende Santos Caillaux⁴
Rafael Vicente de Souza e Paula⁵
Felipe Augusto Lara Soares⁶

Resumo

A deterioração clínica de pacientes internados em enfermarias é frequentemente detectada de forma tardia, em razão do monitoramento intermitente dos sinais vitais. Este trabalho propõe um sistema embarcado de beira de leito que monitora continuamente os sinais vitais, calcula o escore de alerta precoce NEWS2 na borda e prediz sua evolução por meio de aprendizado de máquina. O dispositivo é construído sobre uma Raspberry Pi 3B+ com sistema operacional Linux customizado gerado pelo Buildroot, integrando sensores de fotopletismografia e de temperatura, interface gráfica em Qt e periféricos de alerta. Para a predição, são comparados três modelos de vieses indutivos distintos (regressão logística, XGBoost e LSTM), treinados sobre uma base pública de pacientes hospitalizados. Como resultados preliminares, o *hardware* foi definido e adquirido, os pacotes do sistema operacional embarcado foram definidos no Buildroot e a base de dados que fundamenta o modelo preditivo foi normalizada e preparada para o treinamento. Os avanços confirmam a viabilidade da solução, cuja finalização e validação serão conduzidas na etapa seguinte do trabalho.

Palavras-chave: NEWS2. Deterioração clínica. Sistemas embarcados. Aprendizado de máquina. Computação em borda.

¹Engenharia de Computação, PUC Minas– Belo Horizonte, Brasil– am.magno2@gmail.com

²Engenharia de Computação, PUC Minas– Belo Horizonte, Brasil– gabrielceconello@hotmail.com

³Engenharia de Computação, PUC Minas– Belo Horizonte, Brasil– paulactalim@gmail.com

⁴Engenharia de Computação, PUC Minas– Belo Horizonte, Brasil– pedro.caillaux@gmail.com

⁵Engenharia de Computação, PUC Minas– Belo Horizonte, Brasil– rafavicente1112@gmail.com

⁶Docente, PUC Minas– Belo Horizonte, Brasil– falarasoares@gmail.com

Abstract

The clinical deterioration of patients in hospital wards is often detected late, owing to the intermittent monitoring of vital signs. This work proposes a bedside embedded system that continuously monitors vital signs, computes the NEWS2 early warning score at the edge, and predicts its evolution through machine learning. The device is built on a Raspberry Pi 3B+ running a custom embedded Linux generated with Buildroot, integrating photoplethysmography and temperature sensors, a Qt graphical interface, and alert peripherals. For the prediction, three models with distinct inductive biases (logistic regression, XGBoost, and LSTM) are compared, trained on a public dataset of hospitalized patients. As preliminary results, the hardware was defined and acquired, the embedded operating system packages were defined in Buildroot, and the dataset underlying the predictive model was normalized and prepared for training. These advances confirm the feasibility of the solution, whose completion and validation will be carried out in the next stage of the work.

Keywords: NEWS2. Clinical deterioration. Embedded systems. Machine learning. Edge computing.

1 INTRODUÇÃO

A deterioração clínica de pacientes hospitalizados representa um importante desafio para a garantia da saúde, especialmente em enfermarias, onde o monitoramento é realizado de forma intermitente (VINCENT *et al.*, 2018). Esse quadro se caracteriza pela piora progressiva de parâmetros fisiológicos, podendo evoluir para desfechos graves, como uma parada cardiorrespiratória, uma transferência não planejada para a Unidade de Terapia Intensiva (UTI) e até um óbito hospitalar (GERRY *et al.*, 2020). Portanto, é de suma importância propor métodos eficazes e de baixo custo para uma detecção ágil dessas descompensações, contribuindo assim para a redução de seus impactos.

Nesse cenário, destacam-se os Sistemas de Alerta Precoce (EWS, do inglês *Early Warning Score*), que consistem em ferramentas padronizadas de avaliação clínica (ALAM *et al.*, 2014). Esses sistemas têm como objetivo auxiliar na identificação antecipada da deterioração por meio da análise sistematizada de parâmetros fisiológicos rotineiramente coletados durante os cuidados ao paciente. A partir da atribuição de pontuações a variáveis como frequência respiratória, pressão arterial, frequência cardíaca, temperatura e saturação de oxigênio, obtém-se um escore capaz de indicar o grau de risco do paciente. Entre as implementações mais consagradas dessa metodologia está a Pontuação Nacional de Alerta Precoce (NEWS, do inglês *National Early Warning Score*) e sua versão atualizada, o NEWS2 (GERRY *et al.*, 2020). Estudos apontam que o uso de ferramentas baseadas em EWS apresenta bom desempenho na identificação de eventos críticos iminentes em janelas de curto prazo, como nas primeiras 48 horas (SMITH *et al.*, 2014).

No entanto, segundo Scott *et al.* (2026), apesar de sua eficácia comprovada, a aplicação tradicional desses escores enfrenta dificuldades operacionais críticas. Ela depende de cálculos realizados manualmente à beira do leito pela equipe de enfermagem, utilizando-se de dados obtidos de forma pontual e espaçada. Esse modelo de aferição inconstante cria extensas janelas temporais em que o paciente permanece sem qualquer monitoramento, o que atrasa o reconhecimento do sintoma fisiológico e representa um obstáculo severo em situações de emergência.

Para superar essas barreiras físicas e operacionais, o desenvolvimento de sistemas embarcados apresenta-se como uma solução robusta, uma vez que a personalização do sistema embarcado permite adequá-lo de forma mais eficiente às necessidades apresentadas (GRAZIOSI; BERNARDO; MARTINELLI, 2024). Dessa maneira, o equipamento pode coletar os sinais vitais continuamente e processá-los localmente, sem a necessidade de enviar dados brutos de telemetria de forma ininterrupta, o que previne problemas associados à infraestrutura operacional da rede hospitalar (RANCEA; ANGHEL; CIOARA, 2024).

Integrado a esse ecossistema de *hardware* restrito, o uso de algoritmos de aprendizado de máquina (ML, do inglês *Machine Learning*) tem se mostrado cada vez mais relevante na estratificação de risco clínico. Sendo um subcampo da Inteligência Artificial, essa tecnologia permite aos sistemas inferirem resultados complexos a partir de conjuntos de dados (BERGMANN, n.d.). Os modelos de ML podem ser divididos em supervisionados e não supervisionados. Em

modelos supervisionados, foco deste trabalho, o sistema usa conjuntos de dados rotulados para entender as relações entre entradas e dados de saída, para poder trabalhar na previsão de saídas de novos conjuntos de dados (BELCIC; STRYKER, n.d.).

Diante desse contexto, o presente trabalho tem como objetivo o desenvolvimento de um sistema embarcado para a automatização e predição contínua do protocolo NEWS2. A proposta se fundamenta na necessidade de conferir maior eficiência, padronização e escalabilidade ao processo, reduzindo a dependência de aferições intermitentes e mitigando falhas humanas. Assim, pretende-se oferecer uma solução de monitoramento constante e inteligente que apoie o reconhecimento precoce do agravamento clínico, favorecendo a tomada de decisão em tempo oportuno e elevando a segurança assistencial nas enfermarias.

A seguir, o artigo está organizado da seguinte forma: na Seção 2, são apresentados os fundamentos teóricos que embasam o trabalho proposto, com destaque em abordagens computacionais no contexto de sistemas embarcados e aprendizado de máquina. A Seção 3 analisa os trabalhos correlatos, enquanto a Seção 4 descreve a metodologia adotada. Na Seção 5, discutem-se os experimentos realizados e os resultados obtidos.

2 FUNDAMENTAÇÃO TEÓRICA

Um sistema embarcado é um sistema computacional dedicado, composto por *hardware* e *software*, projetado para executar funções específicas e, diferentemente de computadores tradicionais, esses sistemas interagem continuamente com o mundo real por meio de sensores e atuadores (LEE, 2002). Com isso, a concepção de sistemas embarcados dedicados é fundamental para aplicações que demandam alta confiabilidade e otimização rigorosa de recursos computacionais (GRAZIOSI; BERNARDO; MARTINELLI, 2024).

Em complemento, a aquisição confiável de sinais fisiológicos é essencial para o funcionamento do sistema. Segundo Allen (2007), a fotopletismografia (PPG, do inglês *Photoplethysmography*) é uma técnica óptica não invasiva e de baixo custo amplamente empregada em dispositivos médicos para a detecção de variações no volume sanguíneo no leito microvascular do tecido. O princípio de funcionamento se baseia na iluminação de um tecido periférico, tipicamente o dedo, o lóbulo da orelha ou o pulso, por meio de um diodo emissor de luz (LED, do inglês *Light Emitting Diode*), enquanto um fotodetector mede a intensidade da luz transmitida ou refletida. Como a absorção de luz pelo sangue varia com cada batimento cardíaco, o sinal resultante apresenta dois componentes: um componente pulsátil (AC), sincronizado com os ciclos cardíacos, e uma linha de base lentamente variável (DC), associada à respiração, à atividade do sistema nervoso simpático e à termorregulação.

Além disso, este projeto propõe a construção de um equipamento operando sob um sistema operacional Linux embarcado, estruturado a partir de sistemas de construção (*build systems*), como o *Buildroot*. Essa abordagem de customização em nível de sistema operacional permite extrair o máximo desempenho, estabilidade, segurança e previsibilidade do *hardware*

disponível, gerando uma imagem de sistema enxuta que reduz o consumo de memória e os custos de implementação, requisitos obrigatórios para o funcionamento de dispositivos médicos críticos (PERÄ, 2022; L4B Software, 2021).

Ademais, para o processamento em tempo real na borda, este projeto também propõe o uso de técnicas de aprendizado de máquina, para a análise automatizada e preditiva de dados da saúde. Veldhuis *et al.* (2022) realizaram uma revisão sistemática em 45 artigos da área da saúde e concluíram que o uso de ML contribuiu para a detecção de deterioração clínica, admissão de pacientes em UTI e estimativa de mortalidade, auxiliando médicos e profissionais da saúde na tomada de decisões mais precisas e oportunas.

Os modelos de ML são capazes de aprender padrões complexos a partir de dados históricos, permitindo maior flexibilidade e potencial de generalização para análise de sinais fisiológicos (CHURPEK *et al.*, 2016). Sua aplicação busca complementar e aprimorar os métodos tradicionais por meio de sua capacidade preditiva, especialmente em cenários com maior disponibilidade de dados contínuos. Entretanto, o uso destas técnicas pode ser computacionalmente custoso, o que traz desafios para sua aplicação eficiente em *hardwares* de menor capacidade.

No cenário do monitoramento de sinais vitais, algoritmos supervisionados utilizam dados rotulados para estabelecer relações entre variáveis fisiológicas e diagnósticos clínicos, possibilitando a identificação precoce de padrões associados à deterioração do paciente (NEMATI *et al.*, 2018). A proposta destes modelos visa correlacionar um conjunto de variáveis de entrada, estimando um parâmetro de saída. Essa característica torna essas abordagens particularmente adequadas para sistemas embarcados de monitoramento contínuo, nos quais grandes volumes de dados são gerados e processados em tempo real (HAVEMAN *et al.*, 2022).

Apesar de o EWS ser um sistema consolidado e amplamente utilizado na estratificação de risco clínico, sua principal limitação reside no caráter pontual e intermitente das aferições, em que o escore reflete apenas o estado fisiológico do paciente no momento da medição, sem considerar a trajetória dos sinais vitais ao longo do tempo nem o histórico clínico individual (MURALITHARAN *et al.*, 2021). Essa característica pode resultar em atrasos na detecção de deterioração, especialmente em enfermarias onde a monitorização tradicional ocorre apenas algumas vezes ao dia. Nesse contexto, a integração entre modelos de ML e sistemas de aquisição contínua de sinais fisiológicos permite superar essa limitação, possibilitando não apenas o cálculo automatizado do EWS em tempo real, mas também a predição antecipada de seu valor futuro com base no histórico de medições do paciente (SALEHINEJAD *et al.*, 2023). Essa abordagem viabiliza uma análise mais precisa, contínua e antecipada do risco clínico, ampliando a janela de intervenção disponível para a equipe de saúde.

3 TRABALHOS CORRELATOS

A predição da deterioração clínica de pacientes hospitalizados por meio de técnicas computacionais tem sido amplamente investigada nos últimos anos. Esta seção apresenta uma

revisão de trabalhos correlatos, selecionados por sua similaridade nos objetivos, por explorarem abordagens baseadas em aprendizado de máquina para análise de sinais vitais ou por investigarem o uso de sistemas embarcados e computação em borda na área da saúde.

Weenk *et al.* (2020) investigam o monitoramento contínuo de sinais vitais em enfermarias e demonstram que ele pode reduzir eventos adversos quando comparado a medições intermitentes. Entretanto, tais sistemas geralmente não incorporam modelos preditivos embarcados, limitando-se à coleta e à exibição instantânea dos dados.

Salehinejad *et al.* (2023) aplicaram técnicas de aprendizado de máquina sobre a trajetória longitudinal do *Deterioration Index* (DI), um escore de deterioração clínica calculado no prontuário eletrônico, para prever eventos adversos. Dentre os classificadores avaliados, o XGBoost obteve o melhor desempenho (AUC, do inglês *Area Under the Curve*, de 0,94), superando a aplicação de um limiar fixo sobre o escore. Entretanto, a dependência do DI — escore proprietário do prontuário — limita a reprodução do método em outras instituições.

Scheid *et al.* (2025) desenvolveram um modelo de aprendizado profundo baseado em dispositivos *wearables* que utiliza sinais vitais e dados demográficos como entrada para uma rede neural recorrente (LSTM), prevendo eventos adversos com antecedência de até 17 horas (AUC de 0,89). Apesar dos resultados promissores, a solução depende de infraestrutura computacional mais robusta e não foi projetada para execução totalmente embarcada na borda.

Sadeghi, Ahmadi e Rajabi (2025) propõem um dispositivo *wearable* de baixo custo baseado em um único sensor PPG, o MAX30102, capaz de mensurar FC, SpO₂ e estimar temperatura, além de empregar um modelo *Random Forest* para estimar PA e FR. O sistema classifica os sinais vitais em níveis codificados por cores inspirados no padrão NEWS, contudo não realiza o cálculo do escore agregado nem contempla a predição de risco do paciente.

Giordano, Dheman e Magno (2024) apresentam o SepAI, um sistema de predição precoce de sepse baseado em TinyML e executado diretamente em *wearables*, com uma rede neural convolucional temporal quantizada em um processador ARM Cortex-M33, capaz de prever eventos sépticos com antecedência média de 9,8 horas. O estudo evidencia o potencial da computação em borda aplicada à saúde, porém concentra-se na predição de sepse, sem contemplar protocolos de alerta precoce como EWS ou NEWS.

Ozturk *et al.* (2023) detalha o projeto de um monitor de beira de leito construído sobre um sistema operacional Linux embarcado dedicado, demonstrando a eficácia do *Buildroot* na compilação cruzada (do inglês *cross-compiling*) para a arquitetura ARM, com ganhos de latência e consumo de recursos. O presente trabalho parte das mesmas premissas, mas avança o estado da técnica ao usar essa base não apenas para telemetria, e sim para o processamento preditivo local (computação em borda), aplicando o protocolo NEWS2 de forma nativa e autônoma.

Em síntese, os trabalhos correlatos concentram-se isoladamente em análise preditiva, monitoramento contínuo ou sistemas embarcados, sem integrar escores clínicos consolidados (EWS/NEWS) à execução de modelos preditivos diretamente na borda. A Tabela 1 sintetiza essas características.

Tabela 1 – Comparação entre os trabalhos correlatos quanto ao uso de monitoramento contínuo (Monit.), aprendizado de máquina (ML), protocolos EWS, sistemas embarcados, computação em borda (Edge) e sistemas operacionais customizados (SO Custom.).

Trabalho	Monit.	ML	EWS	Embarcados	Edge	SO Custom.
Weenk et al. (2020)	Sim	Não	Não	Não	Parcial	Não
Salehinejad et al. (2023)	Sim	Sim	Não	Não	Não	Não
Scheid et al. (2025)	Sim	Sim	Não	Parcial	Parcial	Não
Sadeghi et al. (2025)	Sim	Sim	Parcial	Sim	Parcial	Não
Giordano et al. (2024)	Sim	Sim	Não	Sim	Sim	Não
OZTURK et al. (2023)	Sim	Não	Não	Sim	Parcial	Sim
Este trabalho	Sim	Sim	Sim	Sim	Sim	Sim

Fonte: Elaborado pelos autores.

Como evidenciado na Tabela 1, nenhum dos trabalhos analisados reúne, em uma única solução, a aquisição contínua de sinais vitais, o cálculo nativo do NEWS2 e a predição na borda sobre um sistema operacional embarcado customizado. É justamente essa lacuna que o presente trabalho busca preencher.

4 METODOLOGIA

Esta seção apresenta primeiramente os materiais escolhidos para o desenvolvimento do dispositivo, bem como a justificativa para o seu uso. Em seguida, para a descrição do método, adotou-se uma abordagem dividida em etapas direcionadas ao hardware e etapas direcionadas ao software. As etapas voltadas ao hardware abrangem a montagem física do dispositivo e a integração entre a placa de processamento, os sensores e os periféricos. Já as etapas voltadas ao software contemplam a configuração do sistema operacional embarcado, a comunicação com os sensores, o processamento dos sinais fisiológicos, o cálculo do escore NEWS2 e o desenvolvimento do modelo preditivo de deterioração clínica.

4.1 Materiais

A plataforma de processamento é responsável pela execução do sistema operacional embarcado, pela aquisição dos sinais fisiológicos, pelo processamento dos dados coletados, pelo cálculo do escore NEWS2 e pela execução dos modelos de aprendizado de máquina empregados na predição de deterioração clínica. Com isso, foi escolhida a Raspberry Pi 3B+, uma vez que possui ampla documentação para o Buildroot, comunidade ativa, memória RAM de 1 GB, arquitetura quad-core de 64 bits a 1,4 GHz e disponibilidade nativa de interfaces I²C, SPI, HDMI e DSI.

A partir dessa plataforma, a extração dos parâmetros do NEWS2 é realizada por dois sensores. O sensor PPG MAX30102 reúne LEDs vermelho e infravermelho, que viabilizam a

extração da SpO_2 , em um encapsulamento compacto, com ADC de 18 bits e baixo custo. Sua interface I²C é nativamente suportada pelo *kernel* Linux, dispensando *frameworks* de terceiros e viabilizando a implementação de um *driver* dedicado em C++. Já o sensor de temperatura DS18B20 oferece resolução configurável de até 12 bits, correspondente a incrementos de 0,0625°C, e precisão de $\pm 0,5^\circ\text{C}$ na faixa de operação corporal. Sua interface digital 1-Wire, também suportada nativamente pelo *kernel*, dispensa ADC externo e permite a leitura da temperatura diretamente via sistema de arquivos, simplificando a integração ao sistema embarcado.

Para o *feedback* visual, optou-se pelo *display* Waveshare de 7 polegadas, cujo tamanho de tela garante alta legibilidade à beira do leito, com compatibilidade direta via HDMI e suporte a toque capacitivo. Complementando o sistema de alertas, o *buzzer* piezoelétrico emite sinais sonoros quando o escore NEWS2 atinge limiares de risco elevado, enquanto o LED RGB reproduz a codificação de cores do protocolo de forma perceptível à distância. Ambos operam via GPIO, sem circuitos de controle adicionais além de resistores limitadores de corrente.

Quanto à alimentação, optou-se por uma arquitetura conectada diretamente à rede elétrica, o que elimina limitações de autonomia energética e reduz a complexidade do projeto ao dispensar circuitos de gerenciamento de bateria. Para o protótipo, previu-se uma fonte chaveada AC-DC de 5 V, dimensionada para o consumo agregado do sistema e distribuída por um barramento que alimenta em paralelo a plataforma de processamento, o *display* e os demais componentes. A adoção de uma fonte comercial simplifica a implementação do *hardware* e contribui para a segurança operacional, alinhando-se às boas práticas de segurança elétrica para equipamentos eletromédicos estabelecidas pela norma IEC 60601-1 da *International Electrotechnical Commission* (IEC) International Electrotechnical Commission (2020).

Para a modelagem tridimensional da *case* do dispositivo, utilizou-se o *software* Autodesk Fusion, que dispõe de ferramenta CAD (do inglês *computer-aided design*) com recursos de modelagem paramétrica e licenciamento gratuito para fins educacionais. A fabricação do invólucro foi realizada por manufatura aditiva pelo processo de Modelagem por Deposição Fundida (FDM, do inglês *Fused Deposition Modeling*), em razão de seu baixo custo e facilidade de prototipagem, características que favorecem o desenvolvimento iterativo.

Quanto aos materiais, o Ácido Polilático (PLA, do inglês *Polylactic Acid*) foi adotado nas iterações iniciais, em razão de sua facilidade de impressão e baixo custo, enquanto a versão final empregou o Polietileno Tereftalato Glicol (PETG, do inglês *Polyethylene Terephthalate Glycol*), justificado por sua maior resistência térmica e tolerância à limpeza com álcool isopropílico, que é procedimento de higienização padrão em ambientes hospitalares.


No âmbito do *software*, o sistema embarcado, responsável pela comunicação com os sensores, pelo processamento dos sinais e pelo cálculo do NEWS2, foi desenvolvido em C++, escolhido por seu desempenho e controle fino sobre memória, determinantes em ambientes com recursos computacionais limitados (KNUTTILA; XU; MICROSOFT, 2012). O Buildroot foi selecionado como *toolchain* de *cross-compilação* para a construção de um sistema operacional personalizável baseado em Linux, em razão do desempenho demonstrado em trabalhos correlatos (OZTURK *et al.*, 2023).

Para os algoritmos de aprendizado de máquina, adotou-se a linguagem Python, consolidada nesse domínio por seu ecossistema robusto de bibliotecas especializadas e por favorecer a prototipagem rápida. Por fim, a interface gráfica embarcada foi desenvolvida com o *framework* Qt, mantendo o C++ já adotado no restante do sistema embarcado, combinação madura e amplamente utilizada em sistemas embarcados (PROJECT, 2024).

4.2 Método

O método proposto foi dividido em três fluxos principais: *hardware*, *software* embarcado e modelo preditivo. Essa divisão se justifica porque as seis etapas definidas podem ser desenvolvidas de forma paralela, convergindo, ao final, para a etapa de testes e resultados. A Figura 1 apresenta o fluxo geral do método.

Figura 1 – Fluxo geral do método proposto.



Fonte: Elaborado pelos autores.

Etapa HW01: a etapa de testes de bancada consistiu na validação individual de cada componente diretamente sobre a Raspberry Pi 3B+, antes da integração física do dispositivo. Cada sensor foi conectado isoladamente à placa por meio de uma protoboard, o que permitiu verificar a comunicação, a integridade dos sinais e o comportamento elétrico sem a complexi-

dade da montagem completa. O MAX30102 foi validado pelo barramento I²C, confirmando-se o endereçamento do dispositivo e a aquisição do sinal PPG bruto; o DS18B20 foi verificado pelo barramento 1-Wire, incluindo a checagem do resistor de *pull-up* exigido pelo protocolo; os periféricos de alerta, *buzzer* e LED RGB, foram testados via GPIO, e o *display*, pelas interfaces de vídeo e toque. Para cada teste foram desenvolvidos programas em C++ que exercitaram a leitura e o controle dos componentes; esses programas validaram os *drivers* de comunicação e foram posteriormente reaproveitados como base do processo principal da aplicação, desenvolvido em C++ com o *framework* Qt. Essa abordagem incremental de *bring-up* reduziu o risco da etapa de integração, isolando problemas de comunicação ou de configuração ainda na bancada.

Etapas HW02: validados os componentes individualmente, realizou-se a montagem final do protótipo, consolidando a fiação e fixando os elementos no invólucro impresso em PETG. As ligações provisórias de bancada foram substituídas por conexões definitivas e organizadas, reduzindo a probabilidade de mau contato durante a operação contínua. A alimentação partiu de uma fonte chaveada de 5 V conectada a um barramento de distribuição, a partir do qual a Raspberry Pi, o *display* e os ventiladores foram alimentados em paralelo, evitando que toda a corrente trafegasse pela placa de processamento; os sensores e os periféricos de alerta, de baixo consumo, foram alimentados diretamente pelos pinos da Raspberry Pi. Para a gestão térmica, exigida pela operação contínua sob carga de inferência, foram previstos quatro ventiladores: dois de pequeno porte dedicados ao processador e dois maiores para o fluxo de ar interno do invólucro. A fonte foi dimensionada para o consumo agregado desses elementos. O resultado é o dispositivo integrado, fisicamente fechado e pronto para a execução conjunta do *software* embarcado e do modelo preditivo.

Etapas SE01: a primeira etapa do *software* embarcado consistiu na construção da imagem do sistema operacional sobre a qual a aplicação é executada, gerada com o Buildroot a partir da configuração base da Raspberry Pi 3B+. O Buildroot foi adotado por produzir, a partir de uma *toolchain* de compilação cruzada, uma imagem Linux enxuta e reproduzível, com controle fino sobre os pacotes incluídos, característica alinhada às restrições de recursos e aos requisitos de confiabilidade de um dispositivo de uso clínico.

A configuração do *kernel* habilitou, por meio de *device tree overlays*, as interfaces exigidas pelos sensores, I²C para o MAX30102 e 1-Wire para o DS18B20, além da saída de vídeo e da entrada por toque do *display*. Sobre uma base mínima de sistema provida pelo BusyBox, a imagem incorporou os pacotes efetivamente necessários à aplicação: o *runtime* da linguagem C++ e as bibliotecas do *framework* Qt para a interface gráfica, os módulos de *kernel* de comunicação (*i2c-dev*, *w1-gpio* e *w1-therm*) e as dependências de execução do modelo preditivo. A seleção foi mantida em um *defconfig* versionado, garantindo a reproduzibilidade do ambiente e reduzindo o tempo de inicialização e a superfície de falhas do sistema.

Etapas SE02: esta etapa abrangeu o *software* responsável pela leitura dos sensores, pelo processamento dos sinais fisiológicos e pelo cálculo do *score* NEWS2. A leitura do MAX30102 foi feita pela interface */dev/i2c* e a do DS18B20, sensor de temperatura corporal, pelo *driver* *w1-therm*, ambos expostos nativamente pelo *kernel* Linux. A partir do sinal PPG,

a frequência cardíaca (FC) e a saturação de oxigênio (SpO₂) foram extraídas de forma direta, respectivamente pela detecção de picos no componente pulsátil e pela razão de absorção entre os comprimentos de onda vermelho e infravermelho (ALLEN, 2007), enquanto a frequência respiratória (FR) foi estimada a partir das modulações respiratórias do sinal (CHARLTON *et al.*, 2018).

A pressão arterial (PA) é o parâmetro de obtenção não invasiva mais complexa a partir do sinal PPG. Por isso, adotou-se a abordagem mais direta e clinicamente confiável: o registro manual do valor pela equipe de enfermagem por meio da interface do equipamento. Como a pressão arterial é empregada de forma intermitente no NEWS2, essa estratégia atende ao protocolo sem depender de estimativas de menor acurácia.

Os cinco parâmetros foram amostrados em janelas de 30 segundos e, ao fim de cada janela, submetidos ao cálculo do NEWS2 conforme as faixas clínicas do protocolo (SMITH *et al.*, 2013). O escore resultante alimentou tanto a classificação imediata de risco quanto o modelo preditivo descrito adiante.

Etapa SE03: a etapa de desenvolvimento da interface gráfica construiu, com o *framework* Qt, a camada de interação entre o sistema e a equipe de saúde, exibida no *display* de toque capacitivo acoplado à plataforma. A renderização foi desacoplada da aquisição e do processamento dos sinais, executados em *threads* distintas, de modo a preservar a responsividade da interface mesmo durante o processamento contínuo.

A tela foi organizada em duas regiões. A primeira apresenta os cinco sinais vitais que compõem o NEWS2, cada um com seu valor, unidade e a cor correspondente à faixa de pontuação do protocolo, facilitando identificar qual parâmetro está alterado. A segunda concentra os dois principais indicadores: o escore NEWS2 atual, com sua classificação de risco (baixo, médio ou alto), e o NEWS2 estimado para um horizonte futuro pelo modelo preditivo, que indica a tendência de evolução do paciente e auxilia a equipe a antecipar intervenções. Como elementos auxiliares, a interface contempla a identificação do paciente, o registro temporal da última atualização e indicadores do estado dos sensores, sinalizando eventuais perdas de contato ou falhas de leitura que possam comprometer a confiabilidade dos dados exibidos.

Etapa MP01: para o desenvolvimento e a validação dos modelos preditivos, foi utilizado o conjunto de dados disponibilizado em (REYNA *et al.*, 2019). A escolha desse conjunto justifica-se por quatro fatores: (i) sua disponibilidade pública, sem necessidade de processo de credenciamento individual, o que favorece a reprodutibilidade do trabalho; (ii) o volume amostral de 40.336 pacientes, suficiente para o treinamento robusto de modelos com alta capacidade representacional; (iii) a presença de séries temporais com periodicidade horária, contendo as variáveis fisiológicas necessárias ao cálculo do NEWS2; e (iv) o caráter multicêntrico, com dados provenientes de dois sistemas hospitalares distintos (Beth Israel Deaconess Medical Center e Emory University Hospital), o que viabiliza estratégias de validação externa. Cada registro do conjunto corresponde a uma hora de internação de um paciente, e contempla as variáveis fisiológicas FC, SpO₂, temperatura, pressão arterial sistólica (PAS), pressão arterial diastólica (PAD), pressão arterial média (PAM) e FR, além de exames laboratoriais e dados demográficos.

A variável-alvo dos modelos preditivos é o valor do NEWS2, calculado conforme as faixas e pesos definidos pelo Royal College of Physicians (2017). Para cada registro horário do conjunto de dados, o escore foi computado a partir das colunas FC, SpO₂, temperatura, PAS e FR, atribuindo-se a cada variável uma pontuação entre 0 e 3 conforme suas faixas fisiológicas, e somando-se as pontuações parciais para obtenção do escore agregado, que varia de 0 a 20.

O conjunto de dados é processado em quatro etapas sequenciais. Primeiramente, realiza-se a filtragem de pacientes, excluindo-se aqueles com menos de $W + h$ horas de registro, uma vez que estes não comportam a montagem da janela mínima de entrada nem a definição da variável-alvo no horizonte considerado. Em seguida, aplica-se a imputação de valores ausentes por meio da técnica *forward-fill* limitada a uma janela de 4 horas, considerando que medições mais antigas perdem representatividade fisiológica. Para cada valor imputado, uma variável binária adicional é criada de forma a sinalizar a imputação ao modelo, preservando a informação implícita contida no padrão de medição — informação clinicamente relevante, dado que a frequência de aferição é em si um indicador de instabilidade percebida pela equipe assistencial.

Na terceira etapa, são extraídas estatísticas descritivas para cada variável fisiológica dentro da janela $X_{t-W+1:t}$, incluindo média, desvio padrão, valor mínimo, valor máximo, último valor observado e coeficiente angular do ajuste linear sobre a janela. Adiciona-se ainda o valor do NEWS2 calculado para cada um dos W instantes da janela, dado que sua trajetória histórica constitui uma das características mais informativas para a predição, conforme demonstrado por Salehinejad *et al.* (2023). Por fim, todas as variáveis numéricas são normalizadas por padronização *z-score* utilizando estatísticas estimadas exclusivamente sobre o conjunto de treinamento, de modo a evitar vazamento de informação.

Etapla MP02: são avaliados três modelos com vieses indutivos distintos, selecionados de modo a cobrir um espectro de complexidade e a permitir comparações metodologicamente significativas. A regressão logística, com regularização L_2 , atua como modelo de referência (*baseline*) e como análogo computacional ao próprio NEWS2. O segundo modelo é o XGBoost, um algoritmo de *gradient boosting* sobre árvores de decisão amplamente consagrado em tarefas tabulares com séries temporais clínicas (CHURPEK *et al.*, 2016). Por fim, emprega-se uma rede neural recorrente do tipo LSTM (*Long Short-Term Memory*), aplicada diretamente sobre a sequência de sinais vitais reamostrados.

A justificativa metodológica para a comparação desses três modelos reside na cobertura de paradigmas indutivos distintos: linear interpretável, *ensemble* de árvores e rede neural sequencial. Essa escolha permite isolar a contribuição de cada classe de viés indutivo para o desempenho preditivo, ao invés de comparar modelos da mesma família, evitando que os resultados reflitam apenas variações de hiperparâmetros dentro de um único paradigma.

4.3 Cronograma de TCC II

A continuidade do trabalho no TCC II está organizada nas atividades apresentadas na Tabela 2, distribuídas ao longo do semestre seguinte. As frentes de *hardware*, *software* embarcado e modelo preditivo evoluem de forma paralela e convergem para os testes integrados e a validação do sistema.

Tabela 2 – Cronograma das atividades previstas para o TCC II.

Atividade	Ago	Set	Out	Nov	Dez
Treinamento e avaliação dos modelos preditivos	X	X	X		
Montagem física final do dispositivo	X	X			
Integração do <i>software</i> embarcado		X	X	X	
Embarque do modelo preditivo no dispositivo			X	X	
Testes integrados e validação do sistema				X	X
Análise dos resultados e redação do artigo				X	X

Fonte: Elaborado pelos autores.

5 RESULTADOS PRELIMINARES

Esta seção apresenta os resultados alcançados ao longo do TCC I, organizados em três frentes desenvolvidas de forma paralela: a definição e aquisição do *hardware*, a configuração do sistema operacional embarcado e a engenharia de dados que fundamenta o modelo preditivo, principal resultado desta etapa.

No âmbito do *hardware*, o conjunto de componentes do dispositivo foi integralmente definido e adquirido, incluindo a plataforma de processamento Raspberry Pi 3B+, os sensores MAX30102 e DS18B20, o *display* Waveshare de 7 polegadas e os periféricos de alerta. Em paralelo, a impressão 3D do invólucro foi iniciada, com as primeiras iterações voltadas a avaliar o acomodamento dos componentes e o posicionamento dos sensores, etapa que será concluída na montagem final do protótipo.

Quanto ao *software* de base, foi definida a configuração da imagem do sistema operacional embarcado no Buildroot, incluindo a arquitetura-alvo da Raspberry Pi 3B+ e o conjunto de pacotes necessário à aplicação: a base mínima de sistema, as bibliotecas do *framework* Qt, o *runtime* de C++, os módulos de comunicação com os sensores e as dependências de execução do modelo. A definição desses pacotes estabelece a base reproduzível a partir da qual a imagem será gerada e consolidada nas etapas seguintes.

O principal resultado desta etapa foi a construção da engenharia de dados que sustenta o modelo preditivo. A partir do conjunto público de pacientes hospitalizados, os dados foram consolidados e normalizados em um único arquivo estruturado. Como a base disponibiliza as variáveis fisiológicas, mas não o escore NEWS2, este é calculado dinamicamente durante o pré-processamento e incorporado como variável-alvo, sem ser persistido na base original, recurso restrito à fase de treinamento. O pré-processamento contempla ainda a remoção de ruídos e

a padronização das variáveis, preparando o conjunto para o treinamento e a comparação dos modelos previstos. Essa frente concentra o maior avanço do trabalho, pois define o *pipeline* desde os dados brutos até a entrada pronta para o aprendizado de máquina, restando para o TCC II o treinamento, a avaliação e o embarque do modelo no dispositivo.

Em conjunto, os resultados preliminares confirmam a viabilidade das três frentes do projeto e a consistência entre elas: os componentes necessários estão disponíveis e o invólucro em prototipagem, os pacotes do ambiente de execução embarcado estão definidos e a base de dados está normalizada e em pré-processamento para o treinamento do modelo.

6 CONCLUSÃO

Este trabalho propôs um sistema embarcado para o monitoramento contínuo de sinais vitais e a predição da deterioração clínica intra-hospitalar, integrando, em uma única solução de beira de leito, o cálculo nativo do escore NEWS2 e a sua predição por aprendizado de máquina executados diretamente na borda, sobre um sistema operacional Linux customizado.

Ao longo do TCC I, as bases para essa solução foram estabelecidas: o *hardware* foi definido e adquirido, com a impressão do invólucro iniciada; os pacotes do sistema operacional embarcado foram definidos no Buildroot; e a engenharia de dados que sustenta o modelo preditivo avançou de forma significativa, com a base já normalizada e o pré-processamento em desenvolvimento. Esses avanços confirmam a viabilidade técnica da proposta e a articulação entre suas três frentes de desenvolvimento.

A principal contribuição do trabalho reside na integração de elementos que a literatura correlata trata de forma isolada: a aquisição contínua de sinais, o cálculo de um escore clínico consolidado e a execução de modelos preditivos na borda, suportados por um sistema operacional embarcado customizado.

No TCC II, o trabalho será finalizado com a montagem definitiva do dispositivo, o treinamento e a avaliação dos modelos preditivos e a validação do sistema integrado. Nessa etapa, pretende-se conduzir comparações que evidenciem o desempenho da solução, entre elas: o confronto entre os três modelos de aprendizado de máquina adotados (regressão logística, XGBoost e LSTM), a comparação da predição por aprendizado de máquina com o NEWS2 calculado de forma tradicional, e a avaliação da latência e do consumo de recursos da inferência embarcada. Espera-se, com isso, demonstrar que a solução proposta oferece um monitoramento contínuo, automatizado e antecipativo, capaz de ampliar a janela de intervenção da equipe assistencial e de contribuir para a segurança do paciente em ambiente hospitalar.

REFERÊNCIAS

- ALAM, N. *et al.* The impact of the use of the early warning score (ews) on patient outcomes: A systematic review. **Resuscitation**, v. 85, n. 5, p. 587–594, 2014. ISSN 0300-9572. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0300957214000422>>.
- ALLEN, J. Photoplethysmography and its application in clinical physiological measurement. **Physiological Measurement**, IOP Publishing, v. 28, n. 3, p. R1–R39, mar 2007.
- BELCIC, I.; STRYKER, C. **O que é Aprendizado supervisionado?** n.d. Disponível em: <<https://www.ibm.com/br-pt/think/topics/supervised-learning>>.
- BERGMANN, D. **O que é Aprendizado de Máquina?** n.d. Disponível em: <<https://www.ibm.com/br-pt/think/topics/machine-learning>>.
- CHARLTON, P. H. *et al.* Breathing rate estimation from the electrocardiogram and photoplethysmogram: A review. **IEEE Reviews in Biomedical Engineering**, IEEE, v. 11, p. 2–20, 2018.
- CHURPEK, M. M. *et al.* Multicenter comparison of machine learning methods and conventional regression for predicting clinical deterioration on the wards. **Critical Care Medicine**, v. 44, n. 2, p. 368–374, 2016.
- GERRY, S. *et al.* Early warning scores for detecting deterioration in adult hospital patients: systematic review and critical appraisal of methodology. **BMJ**, v. 369, p. m1501, 2020.
- GIORDANO, M.; DHEMAN, K.; MAGNO, M. Sepal: Sepsis alerts on low power wearables with digital biomarkers and on-device tiny machine learning. **arXiv preprint arXiv:2408.08316**, 2024. Disponível em: <<https://arxiv.org/abs/2408.08316>>.
- GRAZIOSI, S. E.; BERNARDO, P. H.; MARTINELLI, M. A. Sistemas embarcados: Fundamentos, aplicações e desafios tecnológicos. **Revista Matiz Online**, 2024. ISSN 21794022. Disponível em: <https://immes.edu.br/wp-content/uploads/2025/05/Artigo_MATIZ_2024_Sistemas_Embarcados.pdf>.
- HAVEMAN, M. E. *et al.* Continuous monitoring of vital signs with wearable sensors during daily life activities: Validation study. **JMIR Formative Research**, v. 6, n. 1, p. e30863, 2022.
- INTERNATIONAL ELECTROTECHNICAL COMMISSION. **IEC 60601-1: Medical Electrical Equipment – Part 1: General Requirements for Basic Safety and Essential Performance**. Geneva, Switzerland, 2020.
- KNUTTILA, F. S.; XU, K.; MICROSOFT. C++: Programação em estilo funcional em C++. **MSDN Magazine**, ago. 2012. Acesso em: 31 mai. 2026. Disponível em: <<https://learn.microsoft.com/pt-br/archive/msdn-magazine/2012/august/c-functional-style-programming-in-c>>. Acesso em: 31 mai. 2026.
- L4B Software. **Why choosing Linux for your Medical Devices?** 2021. Disponível em: <<https://www.l4b-software.com/why-choosing-linux-for-your-medical-devices/>>.
- LEE, E. A. Embedded software. In: ZELKOWITZ, M. V. (Ed.). **Advances in Computers**. Elsevier, 2002, (Advances in Computers, v. 56). p. 55–95. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0065245802800043>>.

MURALITHARAN, S. *et al.* Machine learning-based early warning systems for clinical deterioration: Systematic scoping review. **Journal of Medical Internet Research**, 2021.

NEMATİ, S. *et al.* An interpretable machine learning model for accurate prediction of sepsis in the icu. **Critical Care Medicine**, v. 46, n. 4, p. 547–553, 2018.

OZTURK, E. *et al.* Design of an embedded system: Bedside patient monitor. **International Journal of Embedded Systems and Applications**, v. 13, n. 4, 2023.

PERÄ, T. **Comparison of custom embedded Linux build systems: Yocto and Buildroot**. 2022. Dissertação (Mestrado em Ciência da Computação) — Aalto University, Espoo, Finlândia, 2022. Orientador: Vesa Hirvisalo.

PROJECT, Q. **About Qt/pt**. 2024. Acesso em: 31 mai. 2026. Disponível em: <https://wiki.qt.io/About_Qt/pt>. Acesso em: 31 mai. 2026.

RANCEA, A.; ANGHEL, I.; CIOARA, T. Edge computing in healthcare: Innovations, opportunities, and challenges. **Future Internet**, v. 16, n. 9, 2024. ISSN 1999-5903. Disponível em: <<https://www.mdpi.com/1999-5903/16/9/329>>.

REYNA *et al.* Early prediction of sepsis from clinical data: The physionet/computing in cardiology challenge 2019. **Cardiology Challenge**, 2019.

SADEGHI, H. S.; AHMADI, M.; RAJABI, D. Design and prototyping of an ai-powered wearable device for continuous vital signs monitoring with intelligent alerting. **Scientific Reports**, v. 15, n. 1, p. 1–19, 2025. Disponível em: <<https://www.nature.com/articles/s41598-025-28772-2>>.

SALEHINEJAD, H. *et al.* Novel machine learning model to improve performance of an early warning system in hospitalized patients: a retrospective multisite cross-validation study. **eClinicalMedicine**, 2023.

SCHEID, M. R. *et al.* Development and validation of a clinical wearable deep learning based continuous in-hospital deterioration prediction model. **Nature Communications**, v. 16, p. 9513, 2025.

SCOTT, L. J. *et al.* Does the use of national early warning scores (news or news2) in healthcare settings improve patient outcomes: a systematic review. **Systematic Reviews**, v. 15, p. 73, 2026.

SMITH, G. B. *et al.* The ability of the national early warning score (NEWS) to discriminate patients at risk of early cardiac arrest, unanticipated intensive care unit admission, and death. **Resuscitation**, Elsevier, v. 84, n. 4, p. 465–470, 2013.

SMITH, M. E. B. *et al.* Early warning system scores for clinical deterioration in hospitalized patients: a systematic review. **Annals of the American Thoracic Society**, 2014.

VELDHUIS, L. *et al.* Artificial intelligence for the prediction of in-hospital clinical deterioration: A systematic review. **Critical Care Explorations**, 2022.

VINCENT, J.-L. *et al.* Melhorar a detecção da deterioração do paciente no ambiente geral da enfermaria hospitalar. **European Journal of Anaesthesiology**, v. 35, n. 5, p. 325–333, 2018.

WEENK, M. *et al.* Continuous monitoring of vital signs in the general ward using wearable devices: Randomized controlled trial. **Journal of Medical Internet Research**, v. 22, n. 6, 2020.