



Sistema Embarcado para Monitoramento e Predição de Deterioração Clínica Intra-hospitalar

Embedded System for Monitoring and Prediction of Intra-Hospital Clinical Deterioration

Alberto Magno Machado¹

Gabriel Luís Pinto Cecconello²

Paula Cristina Talim Gonçalves³

Pedro Henrique de Rezende Santos Caillaux⁴

Rafael Vicente de Souza e Paula⁵

Felipe Augusto Lara Soares⁶

¹Engenharia de Computação, PUC Minas– Belo Horizonte, Brasil– am.magno2@gmail.com

²Engenharia de Computação, PUC Minas– Belo Horizonte, Brasil– gabrielceconello@hotmail.com

³Engenharia de Computação, PUC Minas– Belo Horizonte, Brasil– paulactalim@gmail.com

⁴Engenharia de Computação, PUC Minas– Belo Horizonte, Brasil– pedro.caillaux@gmail.com

⁵Engenharia de Computação, PUC Minas– Belo Horizonte, Brasil– rafavicente1112@gmail.com

⁶Docente, PUC Minas– Belo Horizonte, Brasil– falarasouares@gmail.com

1 INTRODUÇÃO

A deterioração clínica de pacientes hospitalizados representa um importante desafio para a garantia da saúde, especialmente em enfermarias, onde o monitoramento é realizado de forma intermitente (VINCENT *et al.*, 2018). Esse quadro se caracteriza pela piora progressiva de parâmetros fisiológicos, podendo evoluir para desfechos graves, como uma parada cardiorrespiratória, uma transferência não planejada para a Unidade de Terapia Intensiva (UTI) e até um óbito hospitalar (GERRY *et al.*, 2020). Portanto, é de suma importância propor métodos eficazes e de baixo custo para uma detecção ágil dessas descompensações, contribuindo assim para a redução de seus impactos.

Nesse cenário, destacam-se os Sistemas de Alerta Precoce (EWS, do inglês *Early Warning Scores*), que consistem em ferramentas padronizadas de avaliação clínica (ALAM *et al.*, 2014). Esses sistemas têm como objetivo auxiliar na identificação antecipada da deterioração por meio da análise sistematizada de parâmetros fisiológicos rotineiramente coletados durante os cuidados ao paciente. **Felipe: acho que não precisa apresentar essas siglas. Elas vão ser usadas depois? Acho que pode deixar a sigla somente do NEWS e NEWS2.** A partir da atribuição de pontuações a variáveis como frequência respiratória (FR), pressão arterial (PA), frequência cardíaca (FC), temperatura (T) e saturação de oxigênio (SpO₂), obtém-se um escore capaz de indicar o grau de risco do paciente. Entre as implementações mais consagradas dessa metodologia está a Pontuação Nacional de Alerta Precoce (NEWS, do inglês *National Early Warning Score*) e sua versão atualizada, o NEWS2 (GERRY *et al.*, 2020). Estudos apontam que o uso de ferramentas baseadas em EWS apresenta bom desempenho na identificação de eventos críticos iminentes em janelas de curto prazo, como nas primeiras 48 horas (SMITH *et al.*, 2014).

No entanto, segundo Scott *et al.* (2026), apesar de sua eficácia comprovada, a aplicação tradicional desses escores enfrenta dificuldades operacionais críticas. Ela depende de cálculos realizados manualmente à beira do leito pela equipe de enfermagem, utilizando-se de dados obtidos de forma pontual e espaçada. Esse modelo de aferição inconstante cria extensas janelas temporais em que o paciente permanece sem qualquer monitoramento, o que atrasa o reconhecimento do sintoma fisiológico e representa um obstáculo severo em situações de emergência.

Para superar essas barreiras físicas e operacionais, o desenvolvimento de sistemas embarcados apresenta-se como uma solução robusta, uma vez que a personalização do sistema embarcado permite adequá-lo de forma mais eficiente às necessidades apresentadas (GRAZIOSI; BERNARDO; MARTINELLI, 2024). Dessa maneira, o equipamento pode coletar os sinais vitais continuamente e processá-los localmente, sem a necessidade de enviar dados brutos de telemetria de forma ininterrupta, o que previne problemas associados infraestrutura operacional da rede hospitalar (RANCEA; ANGHEL; CIOARA, 2024).

Integrado a esse ecossistema de hardware restrito, o uso de algoritmos de Aprendizagem de Máquina (ML, do inglês *Machine Learning*) tem se mostrado cada vez mais relevante na estratificação de risco clínico. Sendo um subcampo da Inteligência Artificial, essa tecnologia permite aos sistemas inferirem resultados complexos a partir de conjuntos de dados (BERGMANN,

n.d.). Os modelos de ML podem ser divididos em supervisionados e não supervisionados. Em modelos supervisionados, foco deste trabalho, o sistema usa conjuntos de dados rotulados para entender as relações entre entradas e dados de saída, para poder trabalhar na previsão de saídas de novos conjuntos de dados (BELCIC; STRYKER, n.d.).

Diante desse contexto, o presente trabalho tem como objetivo o desenvolvimento de um sistema embarcado para a automatização e predição contínua do protocolo EWS. A proposta se fundamenta na necessidade de conferir maior eficiência, padronização e escalabilidade ao processo, reduzindo a dependência de aferições intermitentes e mitigando falhas humanas. Assim, pretende-se oferecer uma solução de monitoramento constante e inteligente que apoie o reconhecimento precoce do agravamento clínico, favorecendo a tomada de decisão em tempo oportuno e elevando a segurança assistencial nas enfermarias.

A seguir, o artigo está organizado da seguinte forma: na Seção 2, são apresentados os fundamentos teóricos que embasam o trabalho proposto, com destaque em abordagens computacionais no contexto de Embarcados e Aprendizagem de Máquina. A Seção 3 analisa os trabalhos correlatos, enquanto a Seção 4 descreve a metodologia adotada. Na Seção 5, discutem-se os experimentos realizados e os resultados obtidos.

2 FUNDAMENTAÇÃO TEÓRICA

Um sistema embarcado é um sistema computacional dedicado, composto por hardware e software, projetado para executar funções específicas e, diferentemente de computadores tradicionais, esses sistemas interagem continuamente com o mundo real por meio de sensores e atuadores (LEE, 2002). Com isso, a concepção de sistemas embarcados dedicados é fundamental para aplicações que demandam alta confiabilidade e otimização rigorosa de recursos computacionais (GRAZIOSI; BERNARDO; MARTINELLI, 2024).

Em complemento, a aquisição confiável de sinais fisiológicos é essencial para o funcionamento do sistema. Segundo Allen (2007), a fotopletismografia (PPG, do inglês *Photoplethysmography*) é uma técnica óptica não invasiva e de baixo custo amplamente empregada em dispositivos médicos para a detecção de variações no volume sanguíneo no leito microvascular do tecido. O princípio de funcionamento se baseia na iluminação de um tecido periférico — tipicamente o dedo, o lóbulo da orelha ou o pulso — por meio de um diodo emissor de luz (LED, do inglês *Light Emitting Diode*), enquanto um fotodetector mede a intensidade da luz transmitida ou refletida. Como a absorção de luz pelo sangue varia com cada batimento cardíaco, o sinal resultante apresenta dois componentes: um componente pulsátil (AC), sincronizado com os ciclos cardíacos, e uma linha de base lentamente variável (DC), associada à respiração, à atividade do sistema nervoso simpático e à termorregulação.

Além disso, este projeto propõe a construção de um equipamento operando sob um sistema operacional Linux embarcado, estruturado a partir de sistemas de construção (*build systems*), como o *Buildroot*. Essa abordagem de customização em nível de sistema operacional

permite extrair o máximo desempenho, estabilidade, segurança e previsibilidade do *hardware* disponível, gerando uma imagem de sistema enxuta que reduz o consumo de memória e os custos de implementação requisitos mandatórios para o funcionamento de dispositivos médicos críticos (PERÄ, 2022; L4B Software, 2021).

Ademais, para o processamento em tempo real na borda, este projeto também propõe o uso de técnicas de Aprendizagem de Máquina, para a análise automatizada e preditiva de dados da saúde. (VELDHUIS *et al.*, 2022) Realizaram uma revisão sistemática em 45 artigos da área da saúde e concluíram que o uso de ML contribuiu para a detecção de deterioração clínica, admissão de pacientes em UTI e estimativa de mortalidade, auxiliando médicos e profissionais da saúde na tomada de decisões mais precisas e oportunas.

Os modelos de ML são capazes de aprender padrões complexos a partir de dados históricos, permitindo maior flexibilidade e potencial de generalização para análise de sinais fisiológicos (CHURPEK *et al.*, 2016). Sua aplicação busca complementar e aprimorar os métodos tradicionais por meio de sua capacidade preditiva, especialmente em cenários com maior disponibilidade de dados contínuos. Entretanto, o uso destas técnicas podem ser computacionalmente custoso, o que traz desafios para sua aplicação eficiente em hardwares de menor capacidade.

No cenário do monitoramento de sinais vitais, algoritmos supervisionados utilizam dados rotulados para estabelecer relações entre variáveis fisiológicas e diagnósticos clínicos, possibilitando a identificação precoce de padrões associados à deterioração do paciente (NEMATI *et al.*, 2018). A proposta destes modelos visa correlacionar um conjunto de variáveis de entrada, estimando um parâmetro de saída. Essa característica torna essas abordagens particularmente adequadas para sistemas embarcados de monitoramento contínuo, nos quais grandes volumes de dados são gerados e processados em tempo real (HAVEMAN *et al.*, 2022).

Apesar de o EWS ser um sistema consolidado e amplamente utilizado na estratificação de risco clínico, sua principal limitação reside no caráter pontual e intermitente das aferições, em que o escore reflete apenas o estado fisiológico do paciente no momento da medição, sem considerar a trajetória dos sinais vitais ao longo do tempo nem o histórico clínico individual (MURALITHARAN *et al.*, 2021). Essa característica pode resultar em atrasos na detecção de deterioração, especialmente em enfermarias onde a monitorização tradicional ocorre apenas algumas vezes ao dia. Nesse contexto, a integração entre modelos de ML e sistemas de aquisição contínua de sinais fisiológicos permite superar essa limitação, possibilitando não apenas o cálculo automatizado do EWS em tempo real, mas também a predição antecipada de seu valor futuro com base no histórico de medições do paciente (SALEHINEJAD *et al.*, 2023). Essa abordagem viabiliza uma análise mais precisa, contínua e antecipada do risco clínico, ampliando a janela de intervenção disponível para a equipe de saúde.

3 TRABALHOS CORRELATOS

A predição da deterioração clínica de pacientes hospitalizados por meio de técnicas computacionais tem sido amplamente investigada nos últimos anos. Esta seção apresenta uma revisão de trabalhos correlatos, selecionados por apresentarem similaridade nos objetivos, explorarem diferentes abordagens baseadas em aprendizado de máquina para análise de sinais vitais e proporem soluções tecnológicas voltadas ao monitoramento contínuo. Adicionalmente, são considerados estudos que, embora não abordem diretamente a predição clínica, investigam o uso de sistemas embarcados, Internet das Coisas e computação em borda na área da saúde, contribuindo com perspectivas relevantes para o desenvolvimento de soluções integradas, como a proposta neste trabalho.

Weenk *et al.* (2020) investigam o uso de sistemas para monitoramento contínuo de sinais vitais em enfermarias, destacando a importância da coleta frequente de dados para a identificação precoce de deterioração clínica. Os autores demonstram que o monitoramento contínuo pode reduzir eventos adversos quando comparado a medições intermitentes. Entretanto, tais sistemas geralmente não incorporam modelos preditivos embarcados, limitando-se à coleta e à exibição dos dados de forma instantânea.

Salehinejad *et al.* (2023) investigaram a aplicação de técnicas de aprendizado de máquina para aprimorar a predição de eventos adversos em pacientes hospitalizados a partir do *Deterioration Index* (DI), um escore de deterioração clínica calculado periodicamente no prontuário eletrônico. Na abordagem convencional avaliada no estudo, pacientes eram classificados como de alto risco quando o DI ultrapassava o limiar de 60 pontos. No entanto, os modelos baseados exclusivamente nesse limiar apresentaram desempenho limitado, com AUC (do inglês *Area Under Curve*) entre 0,56 e 0,57. Para superar essa limitação, os autores propuseram um modelo capaz de explorar a trajetória longitudinal dos escores de DI ao longo da internação, representando essas séries temporais por meio de *random convolution kernels*. Diferentes classificadores foram avaliados, incluindo Ridge, SVM e XGBoost, sendo este último o de melhor desempenho, com AUC de 0,94 e acurácia de 0,88 na predição de eventos adversos. Os resultados indicam que a análise do histórico temporal dos escores de deterioração pode ser mais informativa do que a aplicação de um único limiar fixo. Entretanto, uma limitação relevante do estudo é a dependência do *Deterioration Index* (DI), escore proprietário gerado no ambiente do prontuário eletrônico dos casos de estudo. Dessa forma, embora o modelo apresente desempenho elevado no contexto analisado, sua reprodução e aplicação direta em outras instituições podem ser limitadas pela disponibilidade desse escore e pelas particularidades dos sistemas hospitalares utilizados.

Scheid *et al.* (2025) desenvolveram e validaram um modelo de aprendizado profundo baseado em dispositivos *wearables* para predição contínua de deterioração clínica intra-hospitalar. O sistema utiliza sinais vitais monitorados continuamente, associados a dados demográficos, como entrada para uma rede neural recorrente (LSTM), capaz de prever eventos clínicos adversos com antecedência de até 17 horas. Os autores demonstram que o modelo apresenta desem-

penho superior aos métodos tradicionais baseados em observações episódicas, alcançando AUC de 0,89 na detecção de alertas clínicos. Apesar dos resultados promissores, a solução depende de infraestrutura computacional mais robusta e não foi projetada para execução totalmente embarcada em dispositivos de borda.

No âmbito do desenvolvimento de hardware para monitoramento fisiológico, Sadeghi, Ahmadi e Rajabi (2025) propõem o design e a prototipação de um dispositivo *wearable* de baixo custo baseado em um único sensor PPG, o MAX30102. O sistema é capaz de mensurar FC, SpO₂ e estimar T, além de empregar um modelo *Random Forest* — posteriormente simplificado para execução embarcada — para estimar PA e FR. Os resultados indicam que o uso de aprendizado de máquina sobre os dados do sensor permite a obtenção de estimativas com precisão satisfatória. O sistema ainda classifica os sinais vitais em níveis codificados por cores inspirados no padrão NEWS, contudo não realiza o cálculo do score agregado nem contempla predições de risco do paciente.

Giordano, Dheman e Magno (2024) apresentam o SepAI, um sistema de predição precoce de sepse baseado em TinyML e executado diretamente em dispositivos *wearables* de baixo consumo energético. A solução utiliza sinais fisiológicos adquiridos por sensores vestíveis, como PPG e temperatura corporal, processados localmente por uma rede neural convolucional temporal quantizada, implementada em um processador ARM Cortex-M33. O modelo foi capaz de prever eventos sépticos com antecedência média de 9,8 horas, mantendo baixa latência e reduzido consumo energético. O estudo evidencia o potencial do processamento em borda aplicado à saúde, porém concentra-se especificamente na predição de sepse, não contemplando protocolos clínicos amplamente utilizados em ambiente hospitalar, como EWS ou NEWS.

Estudos na área de arquiteturas de hardware e software para ambientes de cuidados intensivos, detalham o projeto de um monitor de beira de leito construído sobre um Sistema Operacional Linux Embarcado dedicado (OZTURK *et al.*, 2023). Os autores demonstram a eficácia da utilização da ferramenta *Buildroot* para a compilação cruzada (do inglês *cross-compiling*) do sistema sob a arquitetura ARM, provando que essa abordagem otimiza o uso de recursos e reduz drasticamente a latência e o consumo computacional. O presente trabalho se apoia nas mesmas premissas de engenharia, contudo, avança o estado da técnica ao usar essa base otimizada do *Buildroot* não apenas para a aquisição e telemetria de sinais em rede, mas para suportar processamento matemático preditivo local (*Edge Computing*) aplicando o protocolo EWS de forma nativa e autônoma.

Sendo assim, observa-se que os trabalhos correlatos seguem, em geral, três direções principais: análise preditiva baseada em registros clínicos históricos, monitoramento contínuo de sinais vitais e desenvolvimento de sistemas embarcados para aquisição e processamento de dados. Além disso, destaca-se o uso de sistemas operacionais embarcados customizados, especialmente aqueles baseados em ferramentas como o *Buildroot*, que permitem a construção de ambientes otimizados e adaptados a requisitos específicos de desempenho e consumo de recursos. No entanto, essas abordagens costumam ser tratadas de forma isolada, sem integração com escores clínicos consolidados, como o EWS ou o NEWS, e sem a incorporação de modelos

preditivos executados diretamente na borda. A Tabela 1 sintetiza as principais características dos trabalhos analisados.

Tabela 1 – Comparação entre os trabalhos correlatos quanto ao uso de monitoramento contínuo (Monit.), aprendizado de máquina (ML), protocolos EWS, sistemas embarcados, computação em borda (Edge) e sistemas operacionais customizados (SO Custom.).

Trabalho	Monit.	ML	EWS	Embarcados	Edge	SO Custom.
Weenk et al. (2020)	Sim	Não	Não	Não	Parcial	Não
Salehinejad et al. (2023)	Sim	Sim	Não (Usa DI)	Não	Não	Não
Scheid et al. (2025)	Sim	Sim	Não	Parcial	Parcial	Não
Sadeghi et al. (2025)	Sim	Sim	Parcial	Sim	Parcial	Não
Giordano et al. (2024)	Sim	Sim	Não	Sim	Sim	Não
OZTURK et al. (2023)	Sim	Não	Não	Sim	Parcial	Sim
Este trabalho	Sim	Sim	Sim	Sim	Sim	Sim

Fonte: Elaborado pelos autores.

Diante do exposto, observa-se que nenhum dos trabalhos analisados reúne, em uma única solução, a aquisição contínua de sinais vitais, o cálculo nativo de escores clínicos consolidados (EWS/NEWS) e a execução de modelos preditivos diretamente na borda, suportados por um sistema operacional embarcado customizado. Abordagens como a de (GIORDANO; DHEMAN; MAGNO, 2024) aproximam-se dessa integração ao executar predição em borda, mas restringem-se à sepse e não incorporam protocolos de alerta precoce; soluções baseadas em SO customizado, como a de (OZTURK *et al.*, 2023), otimizam o ambiente embarcado, porém limitam-se à telemetria, sem processamento preditivo local. É justamente essa lacuna que o presente trabalho busca preencher, propondo uma solução integrada que aplica o protocolo EWS de forma nativa e autônoma na borda, viabilizando a predição antecipada da deterioração clínica em ambiente hospitalar.

4 METODOLOGIA

Esta seção apresenta primeiramente os materiais escolhidos para o desenvolvimento do dispositivo, bem como a justificativa para o seu uso. Em seguida, para a descrição do método, adotou-se uma abordagem dividida em etapas direcionadas ao hardware e etapas direcionadas ao software. As etapas voltadas ao hardware abrangem a montagem física do dispositivo e a integração entre a placa de processamento, os sensores e os periféricos. Já as etapas voltadas ao software contemplam a configuração do sistema operacional embarcado, a comunicação com os sensores, o processamento dos sinais fisiológicos, o cálculo do escore NEWS2 e o desenvolvimento do modelo preditivo de deterioração clínica.

4.1 Materiais

A plataforma de processamento é responsável pela execução do sistema operacional embarcado, pela aquisição dos sinais fisiológicos, pelo processamento dos dados coletados, pelo cálculo do escore NEWS2 e pela execução dos modelos de aprendizado de máquina empregados na predição de deterioração clínica. Com isso, foi escolhido a Raspberry Pi 3B+, uma vez que possui ampla documentação ao Buildroot, comunidade ativa, memória RAM de 1GB, arquitetura quad-core de 64 bits a 1,4 GHz e disponibilidade nativa de interfaces I²C, SPI, HDMI e DSI

A partir dessa plataforma, a extração dos parâmetros do NEWS2 é realizada por dois sensores. O sensor PPG MAX30102 reúne LEDs vermelho e infravermelho — que viabilizam a extração da SpO₂ — em um encapsulamento compacto, com ADC de 18 bits e baixo custo. Sua interface I²C é nativamente suportada pelo kernel Linux, dispensando *frameworks* de terceiros e viabilizando a implementação de um *driver* dedicado em C++. Já o sensor de temperatura DS18B20 oferece resolução configurável de até 12 bits, correspondente a incrementos de 0,0625°C, e precisão de ±0,5°C na faixa de operação corporal. Sua interface digital 1-Wire, também suportada nativamente pelo kernel, dispensa ADC externo e permite a leitura da temperatura diretamente via sistema de arquivos, simplificando a integração ao sistema embarcado.

Para o *feedback* visual, optou-se pelo *display* Waveshare de 7 polegadas, cujo tamanho de tela garante alta legibilidade à beira do leito, com compatibilidade direta via HDMI e suporte a toque capacitivo. Complementando o sistema de alertas, o *buzzer* piezoelétrico emite sinais sonoros quando o escore NEWS2 atinge limiares de risco elevado, enquanto o LED RGB reproduz a codificação de cores do protocolo de forma perceptível à distância. Ambos operam via GPIO, sem circuitos de controle adicionais além de resistores limitadores de corrente.

Quanto à alimentação, optou-se por uma arquitetura conectada diretamente à rede elétrica, o que elimina limitações de autonomia energética e reduz a complexidade do projeto ao dispensar circuitos de gerenciamento de bateria. Para o protótipo, prevê-se uma fonte chaveada AC-DC de 5 V e 3 A, responsável por alimentar todos os componentes do dispositivo. A adoção de uma fonte comercial simplifica a implementação do *hardware* e contribui para a segurança operacional, alinhando-se às boas práticas de segurança elétrica para equipamentos eletromédicos estabelecidas pela norma IEC 60601-1 da *International Electrotechnical Commission* (IEC) International Electrotechnical Commission (2020).

Para a modelagem tridimensional da *case* do dispositivo, utilizou-se o software Autodesk Fusion, que dispõe de ferramenta CAD (do inglês *computer-aided design*) com recursos de modelagem paramétrica e licenciamento gratuito para fins educacionais. A fabricação do invólucro foi realizada por manufatura aditiva pelo processo de Modelagem por Deposição Fundida (FDM, do inglês *Fused Deposition Modeling*), em razão de seu baixo custo e facilidade de prototipagem, características que favorecem o desenvolvimento iterativo.

Quanto aos materiais, o Ácido Polilático (PLA, do inglês *Polylactic Acid*) foi adotado

nas iterações iniciais, em razão de sua facilidade de impressão e baixo custo, enquanto a versão final empregou o Polietileno Tereftalato Glicol (PETG, do inglês *Polyethylene Terephthalate Glycol*), justificado por sua maior resistência térmica e tolerância à limpeza com álcool isopropílico, que é procedimento de higienização padrão em ambientes hospitalares.

No âmbito do software, o sistema embarcado, responsável pela comunicação com os sensores, pelo processamento dos sinais e pelo cálculo do NEWS2, foi desenvolvido em C++, escolhido por seu desempenho e controle fino sobre memória, determinantes em ambientes com recursos computacionais limitados (KNUTTILA; XU; MICROSOFT, 2012). O Buildroot foi selecionado como *toolchain* de *cross-compilação* para a construção de um sistema operacional personalizável baseado em Linux, em razão do desempenho demonstrado em trabalhos correlatos (OZTURK et al., 2023).

Para os algoritmos de aprendizado de máquina, adotou-se a linguagem Python, consolidada nesse domínio por seu ecossistema robusto de bibliotecas especializadas e por favorecer a prototipagem rápida. Por fim, a interface gráfica embarcada foi desenvolvida com o *framework* Qt, mantendo o C++ já adotado no restante do sistema embarcado, combinação madura e amplamente utilizada em sistemas embarcados (PROJECT, 2024).

4.2 Método

O método proposto foi dividido em três fluxos principais: *hardware*, *software* embarcado e modelo preditivo. Essa divisão se justifica porque as seis etapas definidas podem ser desenvolvidas de forma paralela, convergindo, ao final, para a etapa de testes e resultados. A Figura 1 apresenta o fluxo geral do método.


Etapas HW01:

Etapas SE01: a primeira etapa do *software* embarcado compreende a construção da imagem do sistema operacional sobre a qual a aplicação será executada, gerada por meio do Buildroot a partir da configuração base correspondente à Raspberry Pi 3B+. A imagem é configurada para incluir o suporte do *kernel* às interfaces de comunicação utilizadas pelos sensores, I²C para o MAX30102 e 1-Wire para o DS18B20, além da saída de vídeo e da entrada por toque do *display*.

Sobre essa base, são incorporados os pacotes e bibliotecas necessários às demais etapas do projeto, como o ambiente de execução da aplicação embarcada, o *framework* gráfico e as dependências do modelo preditivo. A imagem é mantida enxuta, contendo apenas os componentes efetivamente utilizados, em conformidade com a natureza embarcada do sistema e os recursos limitados da plataforma.

Etapas SE02: a seguinte etapa compreende o desenvolvimento do *software* embarcado responsável pela comunicação com os sensores, pelo processamento dos sinais fisiológicos e pelo cálculo do escore NEWS2.

A leitura do MAX30102 foi realizada por meio da interface `/dev/i2c` exposta nativamente

Figura 1 – Fluxo geral do método proposto.

Fonte: Elaborado pelos autores.

pelo kernel Linux. A partir do sinal PPG bruto adquirido, dois parâmetros foram extraídos de forma direta, a frequência cardíaca, obtida pela detecção de picos no componente pulsátil (AC) do sinal, e a saturação de oxigênio, calculada pela razão de absorção entre os comprimentos de onda vermelho e infravermelho emitidos pelo sensor (ALLEN, 2007). A frequência respiratória foi estimada a partir das modulações respiratórias presentes no sinal PPG — variação de linha de base, modulação de amplitude e modulação de frequência dos intervalos inter-batimento —, seguindo as abordagens descritas por Charlton *et al.* (2018). A leitura da temperatura corporal foi realizada via driver *wl-therm*, nativo do kernel Linux, que expõe o valor medido pelo DS18B20 diretamente por meio do sistema de arquivos em */sys/bus/w1/devices*.

A estimativa de pressão arterial (PA) representa o parâmetro de maior complexidade de obtenção não invasiva a partir do sinal PPG. A abordagem adotada se baseia na extração de características morfológicas do sinal PPG, como tempo de trânsito do pulso, largura e amplitude dos picos, e na aplicação de um modelo de aprendizado de máquina para estimativa dos valores sistólico e diastólico, estratégia com precedente direto na literatura (SADEGHI; AHMADI; RAJABI, 2025). O modelo foi treinado previamente em ambiente externo ao dispositivo embarcado e exportado em formato compatível com inferência embarcada em C++.

Os cinco parâmetros fisiológicos obtidos foram amostrados em janelas temporais de 30 segundos, ao fim das quais os valores representativos de cada parâmetro foram submetidos ao cálculo do escore NEWS2. A pontuação de cada parâmetro foi determinada conforme as

faixas clínicas definidas pelo protocolo (SMITH *et al.*, 2013), e o escore agregado resultante foi utilizado tanto para a classificação imediata do risco do paciente quanto como entrada para o modelo preditivo de deterioração clínica descrito na etapa seguinte.

Etapa SE03: a etapa de desenvolvimento da interface gráfica compreende a construção da camada de interação entre o sistema e a equipe de saúde, exibindo as informações no *display* de toque capacitivo acoplado à plataforma de processamento.

A tela foi organizada em duas regiões. A primeira apresenta os cinco sinais vitais que compõem o NEWS2, cada um com seu valor, unidade e a cor correspondente à faixa de pontuação do protocolo, facilitando identificar qual parâmetro está alterado. A segunda concentra os dois principais indicadores do sistema: o escore NEWS2 atual, com sua classificação de risco, baixo, médio ou alto, e o NEWS2 estimado para um horizonte futuro pelo modelo preditivo, que indica a tendência de evolução do paciente e auxilia a equipe a antecipar intervenções.

Como elementos auxiliares, a interface contempla ainda a identificação do paciente, o registro temporal da última atualização das medições e indicadores do estado de funcionamento dos sensores, sinalizando eventuais perdas de contato ou falhas de leitura que possam comprometer a confiabilidade dos dados exibidos.

Etapa MP01: para o desenvolvimento e a validação dos modelos preditivos, foi utilizado o conjunto de dados disponibilizado em (REYNA *et al.*, 2019). A escolha desse conjunto justifica-se por quatro fatores: (i) sua disponibilidade pública, sem necessidade de processo de credenciamento individual, o que favorece a reprodutibilidade do trabalho; (ii) o volume amostral de 40.336 pacientes, suficiente para o treinamento robusto de modelos com alta capacidade representacional; (iii) a presença de séries temporais com periodicidade horária, contendo as variáveis fisiológicas necessárias ao cálculo do NEWS2; e (iv) o caráter multicêntrico, com dados provenientes de dois sistemas hospitalares distintos (Beth Israel Deaconess Medical Center e Emory University Hospital), o que viabiliza estratégias de validação externa. Cada registro do conjunto corresponde a uma hora de internação de um paciente, e contempla as variáveis fisiológicas FC, SpO₂, temperatura, PAS, pressão arterial diastólica, pressão arterial média e FR, além de exames laboratoriais e dados demográficos.

A variável-alvo dos modelos preditivos é o valor do NEWS2, calculado conforme as faixas e pesos definidos pelo Royal College of Physicians (2017). Para cada registro horário do conjunto de dados, o escore foi computado a partir das colunas FC, SpO₂, temperatura, PAS e FR, atribuindo-se a cada variável uma pontuação entre 0 e 3 conforme suas faixas fisiológicas, e somando-se as pontuações parciais para obtenção do escore agregado, que varia de 0 a 20.

O conjunto de dados é processado em quatro etapas sequenciais. Primeiramente, realiza-se a filtragem de pacientes, excluindo-se aqueles com menos de $W + h$ horas de registro, uma vez que estes não comportam a montagem da janela mínima de entrada nem a definição da variável-alvo no horizonte considerado. Em seguida, aplica-se a imputação de valores ausentes por meio da técnica *forward-fill* limitada a uma janela de 4 horas, considerando que medições mais antigas perdem representatividade fisiológica. Para cada valor imputado, uma variável binária adicional é criada de forma a sinalizar a imputação ao modelo, preservando a informa-

ção implícita contida no padrão de medição — informação clinicamente relevante, dado que a frequência de aferição é em si um indicador de instabilidade percebida pela equipe assistencial.

Na terceira etapa, são extraídas estatísticas descritivas para cada variável fisiológica dentro da janela $X_{t-W+1:t}$, incluindo média, desvio padrão, valor mínimo, valor máximo, último valor observado e coeficiente angular do ajuste linear sobre a janela. Adiciona-se ainda o valor do NEWS2 calculado para cada um dos W instantes da janela, dado que sua trajetória histórica constitui uma das características mais informativas para a predição, conforme demonstrado por Salehinejad *et al.* (2023). Por fim, todas as variáveis numéricas são normalizadas por padronização z -score utilizando estatísticas estimadas exclusivamente sobre o conjunto de treinamento, de modo a evitar vazamento de informação.

Etapas MP02: são avaliados três modelos com vieses indutivos distintos, selecionados de modo a cobrir um espectro de complexidade e a permitir comparações metodologicamente significativas. A regressão logística, com regularização L_2 , atua como modelo de referência (*baseline*) e como análogo computacional ao próprio NEWS2 que, o modelo XGBoost, um algoritmo de *gradient boosting* sobre árvores de decisão amplamente consagrado em tarefas tabulares com séries temporais clínicas (CHURPEK *et al.*, 2016) e uma rede neural recorrente do tipo LSTM (*Long Short-Term Memory*), aplicada diretamente sobre a sequência de sinais vitais reamostrados.

A justificativa metodológica para a comparação desses três modelos reside na cobertura de paradigmas indutivos distintos: linear interpretável, *ensemble* de árvores e rede neural sequencial. Essa escolha permite isolar a contribuição de cada classe de viés indutivo para o desempenho preditivo, ao invés de comparar modelos da mesma família, evitando que os resultados reflitam apenas variações de hiperparâmetros dentro de um único paradigma.

5 RESULTADOS E DISCUSSÃO

6 CRONOGRAMA E CONSIDERAÇÕES FINAIS

REFERÊNCIAS

- ALAM, N. *et al.* The impact of the use of the early warning score (ews) on patient outcomes: A systematic review. **Resuscitation**, v. 85, n. 5, p. 587–594, 2014. ISSN 0300-9572. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0300957214000422>>.
- ALLEN, J. Photoplethysmography and its application in clinical physiological measurement. **Physiological Measurement**, IOP Publishing, v. 28, n. 3, p. R1–R39, mar 2007.
- BELCIC, I.; STRYKER, C. **O que é Aprendizado supervisionado?** n.d. Disponível em: <<https://www.ibm.com/br-pt/think/topics/supervised-learning>>.
- BERGMANN, D. **O que é Aprendizado de Máquina?** n.d. Disponível em: <<https://www.ibm.com/br-pt/think/topics/machine-learning>>.
- CHARLTON, P. H. *et al.* Breathing rate estimation from the electrocardiogram and photoplethysmogram: A review. **IEEE Reviews in Biomedical Engineering**, IEEE, v. 11, p. 2–20, 2018.
- CHURPEK, M. M. *et al.* Multicenter comparison of machine learning methods and conventional regression for predicting clinical deterioration on the wards. **Critical Care Medicine**, v. 44, n. 2, p. 368–374, 2016.
- GERRY, S. *et al.* Early warning scores for detecting deterioration in adult hospital patients: systematic review and critical appraisal of methodology. **BMJ**, v. 369, p. m1501, 2020.
- GIORDANO, M.; DHEMAN, K.; MAGNO, M. Sepal: Sepsis alerts on low power wearables with digital biomarkers and on-device tiny machine learning. **arXiv preprint arXiv:2408.08316**, 2024. Disponível em: <<https://arxiv.org/abs/2408.08316>>.
- GRAZIOSI, S. E.; BERNARDO, P. H.; MARTINELLI, M. A. Sistemas embarcados: Fundamentos, aplicações e desafios tecnológicos. **Revista Matiz Online**, 2024. ISSN 21794022. Disponível em: <https://immes.edu.br/wp-content/uploads/2025/05/Artigo_MATIZ_2024_Sistemas_Embarcados.pdf>.
- HAVEMAN, M. E. *et al.* Continuous monitoring of vital signs with wearable sensors during daily life activities: Validation study. **JMIR Formative Research**, v. 6, n. 1, p. e30863, 2022.
- INTERNATIONAL ELECTROTECHNICAL COMMISSION. **IEC 60601-1: Medical Electrical Equipment – Part 1: General Requirements for Basic Safety and Essential Performance**. Geneva, Switzerland, 2020.
- L4B Software. **Why choosing Linux for your Medical Devices?** 2021. Disponível em: <<https://www.l4b-software.com/why-choosing-linux-for-your-medical-devices/>>.
- LEE, E. A. Embedded software. In: ZELKOWITZ, M. V. (Ed.). **Advances in Computers**. Elsevier, 2002, (Advances in Computers, v. 56). p. 55–95. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0065245802800043>>.
- MURALITHARAN, S. *et al.* Machine learning-based early warning systems for clinical deterioration: Systematic scoping review. **Journal of Medical Internet Research**, 2021.
- NEMATI, S. *et al.* An interpretable machine learning model for accurate prediction of sepsis in the icu. **Critical Care Medicine**, v. 46, n. 4, p. 547–553, 2018.

OZTURK, E. *et al.* Design of an embedded system: Bedside patient monitor. **International Journal of Embedded Systems and Applications**, v. 13, n. 4, 2023.

PERÄ, T. **Comparison of custom embedded Linux build systems: Yocto and Buildroot**. 2022. Dissertação (Mestrado em Ciência da Computação) — Aalto University, Espoo, Finlândia, 2022. Orientador: Vesa Hirvisalo.

RANCEA, A.; ANGHEL, I.; CIOARA, T. Edge computing in healthcare: Innovations, opportunities, and challenges. **Future Internet**, v. 16, n. 9, 2024. ISSN 1999-5903. Disponível em: <<https://www.mdpi.com/1999-5903/16/9/329>>.

REYNA *et al.* Early prediction of sepsis from clinical data: The physionet/computing in cardiology challenge 2019. **Cardiology Challenge**, 2019.

SADEGHI, H. S.; AHMADI, M.; RAJABI, D. Design and prototyping of an ai-powered wearable device for continuous vital signs monitoring with intelligent alerting. **Scientific Reports**, v. 15, n. 1, p. 1–19, 2025. Disponível em: <<https://www.nature.com/articles/s41598-025-28772-2>>.

SALEHINEJAD, H. *et al.* Novel machine learning model to improve performance of an early warning system in hospitalized patients: a retrospective multisite cross-validation study. **eClinicalMedicine**, 2023.

SCHEID, M. R. *et al.* Development and validation of a clinical wearable deep learning based continuous in-hospital deterioration prediction model. **Nature Communications**, v. 16, p. 9513, 2025.

SCOTT, L. J. *et al.* Does the use of national early warning scores (news or news2) in healthcare settings improve patient outcomes: a systematic review. **Systematic Reviews**, v. 15, p. 73, 2026.

SMITH, G. B. *et al.* The ability of the national early warning score (NEWS) to discriminate patients at risk of early cardiac arrest, unanticipated intensive care unit admission, and death. **Resuscitation**, Elsevier, v. 84, n. 4, p. 465–470, 2013.

SMITH, M. E. B. *et al.* Early warning system scores for clinical deterioration in hospitalized patients: a systematic review. **Annals of the American Thoracic Society**, 2014.

VELDHUIS, L. *et al.* Artificial intelligence for the prediction of in-hospital clinical deterioration: A systematic review. **Critical Care Explorations**, 2022.

VINCENT, J.-L. *et al.* Melhorar a detecção da deterioração do paciente no ambiente geral da enfermaria hospitalar. **European Journal of Anaesthesiology**, v. 35, n. 5, p. 325–333, 2018.

WEENK, M. *et al.* Continuous monitoring of vital signs in the general ward using wearable devices: Randomized controlled trial. **Journal of Medical Internet Research**, v. 22, n. 6, 2020.